Homework #2 (Probability & Statistics)

[2024270616 박철원]

Rationale of the Homework #2

(1) Let's apply the statistical hypothesis tests you learned for real medical data via R-programming.

(2) Learn how to import data by referring to Googling or our course textbooks, such as https://rafalab.github.io/dsbook/importing-data.html. The final exam is also a practical exam, so **you must study how to import data**.

[Instruction]

(1) Once you **download** the compressed file from Blackboard and release it, **there will be data.txt**

(2) By placing data.txt file in your Working Directory (setwd(XXX)) and using the fread() function of the data.table package **as following figure**, you can load the data on your computer.

```
library(data.table)
data <- data.frame(fread("Data.txt", sep = "\t", head=T, stringsAsFactors = T))
dim(data)
```

```
> dim(data)
[1] 8921   14
```

The following feature values can be observed in the data, and these are values that are actually used in clinical practice.

Feature	Description
Age	Age at current visit
Gender	Gender (1=Male, 2=Female)
Race	Race of subject (1=White, 2=Black or African American)
Height	Height, cm
Weight	Weight, kg
sysBP	Systolic blood pressure, mmHg
HR	Heart rate (bpm)
Resting_Sa	Resting SaO2, %
BMI	BMI
HaveCoug	Do you usually have a cough (Exclude clearing of throat) 1=Yes, 0=No
FEV1	FEV1 % pred, post-Utah
FVC	FVC % pred, post-Utah
FEV1_FVC	FEV1/FVC, post-Utah
Disease	Class Label

(3) Try to resolve the problems below in this state.
* You can consult with a friend, but copying the R code is absolutely prohibited (It will be shortcut for the F grade).

(4) Please fill in the blanks on the bottom report. **Compress and submit this report (.docx), and the entire R-code (.R file)** you wrote.

***The R-code should be executable when the TA runs.**
***The submitted compressed file (.zip) must be named HW2_YourID_Yourname.zip.**

[Q1] It is known by the NIH of the United States that the systolic blood pressure in normal people follows the following distribution: sysBP ~ N(128.65 , σ =16.5). Let's **perform following hypothesis test under the 5% significance level** to find evidence that COVID19 patients are different from the loaded data.

$$H_0: Collected\ Samples\ are\ not\ biased$$

$$H_1: The\ sample\ collected\ will\ be\ different\ from\ the\ population.$$

(1) Test statistics

검정 통계량(Test Statistic)은 모집단의 표준편차(σ =16.5)가 알려져 있으므로 one sample Z-test를 사용해 계산한다. Data.txt의 전체 표본에 대해 sysBP의 표본 크기는 n=8921명이며, 표본 평균은 약 128.8486이다. 따라서 **검정 통계량 Z는 약 1.1366**이다.

(2) P-value

대립 가설이 "모집단과 다르다"는 가설이므로 양측 검정을 수행한다. 따라서 유의 확률(P-value)은 표준 정규 분포에서 계산된 검정 통계량 절댓값보다 바깥 영역의 넓이의 2배이다. 검정 통계량을 바탕으로 **계산된 P-value는 약 0.2557이다.**

(3) Decision Making at 5% significance level
(*) Use all of the "Null hypothesis", "Reject", "Alternative hypothesis", "Select" and "Significance level" terminology to make a statistical conclusion.

계산된 P-value는 약 0.256으로, 이는 설정된 유의 수준인 0.05보다 크다. 따라서 귀무가설(Null hypothesis)을 기각(Reject)할 수 없다. **즉, 이 표본으로는 대립가설(Alternative hypothesis)을 채택(Select)하기에 충분한 통계적 근거가 없다고 결론 내린다.** 따라서 수집된 전체 표본의 수축기 혈압(sysBP) 평균은 주어진 정규분포 N(128.65, (16.5)^2)를 따르는 **정상인 모집단의 평균과 통계적으로 유의미한 차이가 있다고 보기 어렵다.**

[Q2] Under the same circumstances as [Step 1], please try to test statistically whether **COVID19 patients show higher systolic blood pressure than known national statistics** at 5% significance level.

*Tip: subset() or which() function can be employed to extract COVID19 subjects.

(1) Alternative Hypothesis

COVID19 환자의 수축기 혈압 평균이 국가 통계(128.65)보다 높다.

(2) Null Hypothesis

COVID19 환자의 수축기 혈압 평균은 국가 통계(128.65)와 차이가 없다. (같다.)

(3) Test statistics

모집단의 분산을 알고 있으므로, 검정 통계량 Z는 약 3.3762이다.

(4) P-value

대립가설이 '높다'를 검정하는 우측 검정이므로, 유의 확률은 표준 정규 분포에서 검정 통계량보다 큰 영역의 넓이이다.

따라서, P-value = P(Z > 3.3762)이므로 약 0.000367이다.

(5) Decision Making at 5% significance level

(*) Use all of the "Null hypothesis", "Reject", "Alternative hypothesis", "Select" and "Significance level" terminology to make a statistical conclusion.

유의 확률인 0.000367이 유의 수준(Significance level) 0.05보다 작으므로, 귀무가설(Null hypothesis)을 기각(Reject)한다. 대립가설(Alternative hypothesis)을 채택(Select)하며, 통계적으로 COVID19 환자의 수축기 혈압이 국가 통계 수치보다 높다고 판단할 수 있다.

[Q3] According to the National Institutes of Health (NIH) in the United States, **heart rate in men** is known to follow the distribution: HR_male ~ N(74.62, σ^2=11.1). Based on this, hypothesize and test alternative hypotheses with **three different directions** at 5% significance level, respectively. Also, **please statistically interpret the final outcome clearly through the analysis**.

[Answer]

(1) 가설 설정

세 가지 방향(양측, 우측, 좌측)에 대한 귀무가설(H0)과 대립가설(H1)은 다음과 같다.

1. 양측 검정: 남성의 심박수가 NIH 통계(74.62)와 다른지 검정
   H0: μ = 74.62, **H1**: μ ≠ 74.62
2. 우측 검정: 남성의 심박수가 NIH 통계(74.62)보다 높은지 검정
   H0: μ = 74.62, **H1**: μ > 74.62
3. 좌측 검정: 남성의 심박수가 NIH 통계(74.62)보다 낮은지 검정
   H0: μ = 74.62, **H1**: μ < 74.62

(2) Test statistics

모집단의 분산(11.1)이 알려져 있으므로 Z-test를 수행한다. R을 이용해 분석한 결과 남성 표본의 크기는 4834명이며, 표본 평균은 약 74.7005이다. 이를 바탕으로 계산된 검정통계량 Z값은 1.6790이다.

(3) Statistical Interpretation at 5% Significance Level

유의 수준 0.05 하에서 각 가설에 대한 검정 결과와 통계적 해석은 다음과 같다.

첫째, 양측 검정의 경우 P-value는 약 0.0932이다. 이는 유의 수준 0.05보다 크므로 귀무가설을 기각하지 못한다(Do NOT Reject H0). 즉, 5% 유의 수준에서 남성의 심박수가 국가 통계와 다르다는 충분한 증거가 없다.

둘째, 우측 검정의 경우 P-value는 약 0.0466이다. 이는 유의 수준 0.05보다 작으므로 귀무가설을 기각하고 대립가설을 채택한다(Select H1). 즉, 5% 유의 수준에서 남성의 심박수가 국가 통계보다 높다고 통계적으로 판단할 수 있다.

셋째, 좌측 검정의 경우 P-value는 약 0.9534이다. 이는 유의 수준 0.05보다 훨씬 크므로 귀무가설을 기각하지 못한다(Do NOT Reject H0).

결론적으로 표본 평균(74.7005)이 모집단 평균(74.62)보다 다소 높게 나타났으며, 이는 우측 검정에서만 유의미한 차이(P < 0.05)로 인정된다. 하지만 양측 검정 기준으로는 차이가 유의미하지 않다는 결론을 얻었다.

[Q4] Perform the same analysis as in [Q3] **at 10% significance level**. After that, Please describe what is different from [Q3] and **what you can learn from it.**

[Answer]

(1) Analysis at 10% Significance Level

[Q3]와 동일한 조건에서 유의 수준을 10%(0.10)로 완화하여 양측 검정을 수행한다. 검정 통계량 Z값은 1.6790으로 동일하며, 양측 검정의 P-value 역시 약 0.0932로 동일하다. 이때 P-value(0.0932)가 유의 수준(0.10)보다 작으므로, 이번에는 귀무가설을 기각하고 대립가설을 채택한다(Reject H0, Select H1). 즉, 유의 수준 10% 하에서는 남성의 심박수가 국가 통계와 통계적으로 유의미한 차이가 있다고 결론 내릴 수 있다.

(2) Differences and Learning Points

[Q3]와 [Q4]의 결정적인 차이는 유의 수준(Significance Level)의 설정에 따른 의사결정의 변화이다. 동일한 데이터와 동일한 P-value(0.0932)를 가졌음에도 불구하고, 유의 수준이 5%일 때는 귀무가설을 기각하지 못했으나, 유의 수준을 10%로 높이자 귀무가설을 기각하게 되었다.

이를 통해 통계적 의사결정은 절대적인 진리가 아닌, 연구자가 설정한 유의 수준(허용 가능한 제1종 오류의 최대치)에 따라 달라질 수 있다는 점을 배울 수 있다. 유의 수준을 높이면(0.05 -> 0.10) 귀무가설을 기각하기 쉬워지지만(검정력 증가), 동시에 귀무가설이 참임에도 불구하고 기각할 오류(Type I Error)를 범할 확률 또한 높아진다는 점을 이해할 수 있다.

[Q5] In a basic health checkup for Koreans surveyed by Korea's National Health Insurance, resting SaO2 was known to have an average of 96.0245 and a variance of 8.995. Based on this, please do hypothesis test to conclude whether the currently loaded "Data.txt" is an independent population in terms of resting SaO2. Feel free to set the significance level at an acceptable level, but make sure it leads to the correct conclusion statistically cleanly.

[Answer]

(1) Null & Alternative Hypothesis

- 귀무가설(H0): 로드된 데이터의 평균 휴식기 산소포화도는 한국인 건강검진 통계 평균(96.0245)과 같다. (즉, 독립된 별개의 모집단이 아니다.)
- 대립가설(H1): 로드된 데이터의 평균 휴식기 산소포화도는 한국인 건강검진 통계 평균(96.0245)과 다르다. (즉, 독립된 별개의 모집단이다.)

(2) Test statistics

Z = (96.0666 - 96.0245) / (sqrt(8.995) / sqrt(8921))

모집단의 분산(sigma^2 = 8.995)이 주어졌으므로 Z-test를 수행한다. R을 통해 분석한 결과 표본의 크기는 8921명이며, 표본 평균은 약 96.0666이다. 이를 바탕으로 계산된 검정통계량 Z값은 약 1.3253이다.

(3) P-value

P-value = 2P(Z > 1.3253) ≈ 1.1851

양측 검정(Two-tailed test)을 수행하였으며, 표준 정규 분포에서 Z = 1.3253보다 극단적인 값이 나올 확률(양쪽 꼬리 면적의 합)을 계산하면 약 1.1851이다.

(4) Decision Making

일반적으로 사용하는 유의 수준 0.01, 0.05, 0.10 하에서 검정 결과를 확인한 결과, P-value(0.1851)가 해당 유의 수준들보다 크므로 귀무가설(H0)을 기각하지 못한다. 유의 수준을 더 높인다면(예: 0.20) 귀무가설을 기각하여 "독립된 모집단이다"라는 뒤집힌 통계적 결론을 얻어낼 수는 있지만, 이는 제1종 오류를 범할 위험을 20%나 감수하겠다는 의미이므로 결론의 신뢰도가 매우 낮다고 평가될 것이다.

따라서 통상적인 기준에서는 Data.txt의 휴식기 산소포화도가 한국인 전체 통계와 통계적으로 유의미하게 다르다는 충분한 증거가 없다고 판단하며, **데이터가 한국인 모집단과 다른 독립된 모집단(independent population)이라고 볼 수 없다는 결론을 내린다.**

This is the end of the page.