고려대학교
KOREA UNIVERSITY

Probability and Statistics, HW#3

Your ID#: [2024270616]

Your Name: [박철원]

[Instruction] 안내

(1) Please read and answer the questions carefully. Write your answers in Korean or English.
(문제를 잘 읽고 신중하게 답변하십시오. 영어 또는 한국어로 답안을 작성하세요).

(2) The R-code should be executable when the TA runs. The submitted compressed file (.zip) must be named HW3_YourID_Yourname.zip.
(R 코드는 TA가 돌렸을 시 깔끔하게 돌아가야 하며, 제출될 압축파일은 반드시 HW3_YourID_Yourname.zip 로 명명하여 제출하십시오.)

(3) There is a partial score. Even if you can't resolve it completely, I hope you can try it as far as you can.
(부분 점수가 있으므로, 완벽하게 해결하지 못하더라도 할 수 있는 만큼 시도해 보길 바랍니다.)

[Q1 – Q4] Load "*Q1_Data.tsv*" file. The number of confirmed cases of COVID-19 from 18 independent institutions was collected (*numCOVID* variable). It is also investigated whether each institution is a statistician group or a computer science group (*Job* variable). (*) Use all of the "Null hypothesis", "Reject", "Alternative hypothesis", "Select" and "Significance level" terminology to make a statistical conclusion.

(Kor: "Q1_Data.tsv" 파일을 로드하십시오. 이 자료에는 18개의 독립적인 기관에서 발생한 COVID-19 확진자 수가 numCOVID 변수에 측정되어 있습니다. 또한, 각 기관이 통계학자 그룹인지 전산학자 그룹인지에 대한 정보가 Job 변수에 측정되어 있습니다. **결과에 대해 답변을 할 때 귀무가설, 대립가설, 채택, 기각, 유의수준 단어를 모두 포함하여 논리적**으로 이끌어 내십시오.)

(Q1) Please perform hypothesis testing on **whether occupations have different numbers of COVID-19 cases** using **one parametric** and **one non-parametric** approaches at **5% significance level (10 Points).**

(Kor: 유의수준 5%에서 직업 종류에 따라 코로나 확진자 수가 다르다는 가설검정을 하나의 모수적 방법과 하나의 비 모수적 방법으로 수행하십시오.)

[Answer]

모수적 방법으로는 **독립 2표본 t-검정을 수행**하였다.

Null hypothesis(H_0): 두 직업 집단의 평균 확진자 수는 같다.

Alternative hypothesis(H_1): 두 직업 집단의 평균 확진자 수는 다르다.

유의수준(Significance level)은 문제에서 제시한 바와 같이 0.05로 설정하였다. 분석 결과, 컴퓨터과학자 집단의 평균은 약 5.11, 통계학자 집단의 평균은 약 3.22로 나타났으며, t = 2.5202, df = 16, p-value = 0.02273이 나왔다. p-value가 유의수준 0.05보다 작으므로, t-검정에서는 Null hypothesis를 Reject하고 Alternative hypothesis를 Select한다. 즉, 모수적 관점에서는 직업에 따라 평균 COVID-19 확진자 수가 다르다는 통계적 근거가 있다고 결론 내린다.

비모수적 방법으로는 **Wilcoxon rank-sum test를 사용**하였다.

Null hypothesis(H_0): 두 직업 집단의 분포(또는 위치, 중앙값)는 같다.

Alternative hypothesis(H_1): 두 집단의 분포(위치)가 다르다.

유의수준(Significance level) 0.05에서 검정을 수행한 결과, W = 61.5, p-value = 0.05879가 나왔다. 이 p-value는 0.05보다 크므로, Wilcoxon 검정에서는 Null hypothesis를 Reject하지 못하고 Alternative hypothesis를 Select할 충분한 근거가 없다고 결론 내린다. 따라서 비모수적 관점에서는 직업에 따라 확진자 수가 다르다고 보기에는 통계적으로 유의한 증거가 부족하다고 해석할 수 있다.

(Q2) Among the hypothesis tests performed in (Q1), **which hypothesis test is preferable? Why?** **(20 Points).**

(Kor: (Q1)에서 수행한 가설 검정 중 어떤 가설검정을 수행하는 것이 바람직합니까? 그 이유는 무엇입니까?)

[Answer]

Q1에서 직업에 따라 COVID-19 확진자 수가 다른지를 검정하기 위해 모수적 방법인 2표본 t-test와 비모수적 방법인 Wilcoxon rank-sum test를 수행하였다.

t-test의 가설은 아래와 같이 설정한다.

Null hypothesis(H_0): 두 집단의 평균 확진자 수는 같다.

Alternative hypothesis(H_1): 두 집단의 평균 확진자 수는 다르다.

유의수준 0.05에서 t-test 결과 p-value = 0.02273으로 나타나, Null hypothesis를 Reject하고 Alternative hypothesis를 Select하였다. 즉, 두 직업 집단의 평균 확진자 수가 다르다는 결론을 내린다.

반면, **Wilcoxon rank-sum test**는 두 집단의 분포(또는 위치, 중앙값)가 같은지를 비교하는 비모수적 검정이다.

Null hypothesis(H_0): 두 집단의 분포(위치)는 같다.

Alternative hypothesis(H_1): 두 집단의 분포(위치)는 다르다.

유의수준 0.05에서 Wilcoxon 검정 결과 p-value = 0.05879로, Null hypothesis를 Reject하지 못하였다. 즉, 비모수적 관점에서는 직업에 따른 확진자 수 차이가 통계적으로 유의하다고 보기 어렵다는 결론을 준다.

두 검정 중 어느 것이 더 유용한지를 판단할 때, t-test는 각 집단 자료가 정규분포를 따른다는 비교적 강한 가정을 필요로 하고, 표본 크기가 작거나 데이터가 정수·계수형으로 제한된 경우 그 가정이 잘 맞지 않을 수 있다. 이번 데이터는 각 집단의 표본 수가 9개로 크지 않고, 확진자 수가 작은 정수값 영역에 집중된 형태이므로, 엄밀한 의미에서 정규분포를 가정하기는 다소 무리가 있다. 따라서, 분포 형태에 대한 가정이 필요 없고 순위를 이용해 비교하는 비모수적 Wilcoxon rank-sum test가 더 robust하고 안전한 선택이다.

따라서 Q1에서 수행한 두 가설검정 중에서는, 유의수준 5%에서 직업에 따른 COVID-19 확진자 수 차이를 평가하기 위한 방법으로 비모수적 Wilcoxon rank-sum test가 더 preferable하다고 판단할 수 있다. 이 검정에서는 p-value = 0.05879로 Null hypothesis를 Reject하지 못하므로, 직업에 따라 확진자 수가 다르다고 단정할 만한 통계적 근거는 부족하다는 결론을 내리는 것이 바람직하다.

(Q3) Professor Seo **developed a new Seo-Stat to compare the two groups**. The format was the **absolute value of the difference in median between the two groups**, as shown below. Using this as the test statistic, **please perform the same hypothesis test as (Q1) at the 10% significance level** and reach a conclusion. **(10 Points).**

(Kor: 서교수는 두 그룹을 비교하기 위한 새로운 Seo 통계량을 개발했습니다. 그 형식은 아래와 같이 두 그룹 각각의 중앙값에 대한 절대값 차이 입니다. 제시된 검정통계량을 바탕으로 가설검정의 논리에 따라 10%유의 수준에서 검정을 실시하고 결론에 이르세요.)

$$Seo - Stat = |Median\,(A\ group) - Median\,(B\ group)|$$

[Answer]

Seo-Stat는 두 집단의 중앙값 차이의 절댓값으로 정의되며, 본 데이터에서는 A 그룹을 Computer Scientist, B 그룹을 Statistician으로 두고 Seo-Stat = |Median(A) − Median(B)|를 계산하였다. R 결과에 따르면 ComputerScientist 집단의 중앙값은 6, Statistician 집단의 중앙값은 4로 나타났고, 따라서 관측된 Seo-Stat는 |6 − 4| = 2이다. 이를 검정통계량으로 사용하여, 다음과 같은 가설을 설정하였다.

Null hypothesis(H_0): 두 직업 집단의 중앙값(분포 위치)은 같다.

Alternative hypothesis(H_1): 두 직업 집단의 중앙값(분포 위치)은 다르다.

귀무가설 H_0가 참일 때를 가정하고, 전체 18개 관측값을 임의로 두 집단(각각 9개)으로 나누는 모든 가능한 분할에 대해 Seo-Stat를 계산하는 permutation test를 수행하였다. 즉, 각 분할마다 두 집단의 중앙값 차이의 절댓값을 구하여 Seo-Stat의 귀무분포를 만들고, 관측값 Seo-Stat = 2 이상이 나오는 비율을 p-value로 정의하였다. R 계산 결과 Seo-Stat permutation test의 p-value는 약 0.0880으로 나타났다. 이 값은 Significance level인 0.10보다 작으므로, 10% 유의수준에서 Null hypothesis를 Reject하고 Alternative hypothesis를 Select한다. 따라서 Seo-Stat를 검정통계량으로 사용하는 경우, 두 직업 집단의 중앙값(분포 위치)은 서로 다르다고 볼 통계적 근거가 있다고 결론 내릴 수 있으며, 특히 ComputerScientist 집단의 중앙값이 Statistician 집단보다 더 크다는 점에서 컴퓨터과학자 그룹이 상대적으로 더 많은 COVID-19 확진자 수를 보인다고 해석할 수 있다.

(Q4) **What are the limits of the "*Seo-test statistic*"** that can be used to test for differences between two groups? **Compare it to the format of the statistic you already know**. **(20 Points).**

(Kor: 두 그룹 간 차이를 테스트하는 데 사용할 수 있는 "Seo-검정통계량의" 한계는 무엇입니까? 이미 알고 있는 통계량의 수식과 비교하여 서술하십시오.)

[Answer]

Seo-test Statistic은 정의가 직관적이고, 평균 대신 중앙값을 사용하므로 outlier에 덜 민감하다는 장점이 있지만, 몇 가지 치명적인 한계가 있다. **첫째**, Seo-Stat은 중앙값만을 사용하기 때문에 각 집단의 분포 모양이나 분산(변동성)에 관한 정보를 거의 반영하지 못한다. **둘째**, 절댓값을 취하기 때문에 어느 집단의 값이 더 큰지에 대한 방향성 정보의 손실을 초래한다. **셋째**, 표준화가 되어 있지 않은 원본 데이터 비교로 인해 이 통계량이 귀무가설 아래에서 어떤 분포를 따르는지 t-검정처럼 수학적으로 명료하게 정리하기 어렵다. 따라서 이를 해결하기 위해 permutation test나 부트스트랩과 같은 재표본 방법에 의존해야만 한다는 제약이 있다. **마지막으로**, 데이터가 작고 값이 정수에 제한되어 있을 경우, 가능한 중앙값 조합이 제한적이어서 검정통계량의 해상도가 낮아지는 문제도 있다.

[Q5 – Q8] Load "*Q5_Data.tsv*" file. From a total of 72 people, their disease information (*Disease* variable), height information (*Height* variable), and 1,724 genomic information (Gene_1, Gene_2, …, Gene_1724 variables) were investigated. All genomic data are continuous random variables. (*) Use all of the "Null hypothesis", "Reject", "Alternative hypothesis", "Select" and "Significance level" terminology to make a statistical conclusion.

(Kor: "Q5_Data.tsv" 파일을 불러 오십시오. 이 자료에는 총 72명의 질병정보(Disease 변수), 키 정보(Height 변수), 유전정보 1,724개 (Gene_1, Gene_2, …, Gene_1724 변수들)이 조사되어 있습니다. 모든 유전정보는 연속 랜덤 변수입니다. **결과에 대해 답변을 할 때 귀무가설, 대립가설, 채택, 기각, 유의수준 단어를 모두 포함하여 논리적**으로 이끌어 내십시오.)

Tip: *for()* repetition in R language can be used as follows:** ***for(i in 1:nrow(data) { data[,i] }

(Q5) Please identify the genes that differ between the cancer-group and the normal-group using a hypothesis test at 1% significance level. Please describe how many genes are found. **(10 Points).**

(Kor: 1% 유의수준에서 가설검정을 이용하여 암군과 정상군 사이에 차이가 나는 유전자를 확인하세요. 얼마나 많은 유전자가 발견되었는지 기술하십시오.)

[Answer]

총 72명의 자료에서 Disease 변수를 기준으로 Cancer-group 25명, Healthy-group 47명으로 구분하고, 각 유전자(Gene_1 ~ Gene_1274)에 대해 두 집단 간 차이가 있는지를 검정하였다. 각 유전자에 대해 모수적 방법인 Welch의 two-sample t-test를 사용하였다.

Null hypothesis(H_0): 해당 유전자에 대해 Cancer-group과 Healthy-group의 평균 값은 같다.

Alternative hypothesis(H_1): 해당 유전자에 대해 두 집단의 평균 값은 다르다.

각 유전자에 대해 t-test를 수행하여 p-value를 계산한 뒤, p-value < 0.01인 경우에는 해당 유전자에서 Null hypothesis를 Reject하고 Alternative hypothesis를 Select하였다. 분석 결과, 1,274개의 유전자 중 315개의 유전자에서 p-value가 0.01보다 작게 나타났다. 따라서 Significance level 1%에서, 이 315개의 유전자에 대해서는 Cancer-group과 Healthy-group 사이에 통계적으로 유의한 차이가 있다고 결론 내릴 수 있으며, 나머지 유전자들에 대해서는 Null hypothesis를 Reject할 충분한 근거가 없어 두 집단이 다르다고 보기 어렵다고 해석할 수 있다.

(Q6) Please Identify genes related to the height using hypothesis testing at 1% significance level. Please describe how many genes are found **(10 Points).**

(Kor: 1% 유의수준에서 가설검정을 이용하여 키와 관련된 유전자를 확인하세요. 얼마나 많은 유전자가 발견되었는지 기술하십시오.)

[Answer]

각 유전자에 대해 Height와의 선형적 관련성을 확인하기 위해, **Pearson 상관계수 기반의 상관관계 검정**을 수행하였다. 검정은 양측 검정으로 수행하였다.

Null hypothesis(H_0): 해당 유전자와 Height 사이의 상관계수는 0이다(상관이 없다)

Alternative hypothesis(H_1): 해당 유전자와 Height 사이의 상관계수는 0이 아니다(상관이 있다)

각 유전자에 대해 cor.test 함수를 이용해 Pearson 상관계수와 대응하는 p-value를 계산한 뒤, p-value < 0.01인 유전자를 키와 유의하게 관련된 유전자로 간주하여 Null hypothesis를 Reject하고 Alternative hypothesis를 Select하였다. 분석 결과, 1,274개의 유전자 중에서 총 12개의 유전자에서 p-value가 0.01보다 작게 나타났다. 따라서 Significance level 1%에서 이 12개의 유전자는 Height와 통계적으로 유의한 상관관계를 가지는 유전자라고 결론 내릴 수 있으며, 나머지 유전자들에 대해서는 Null hypothesis를 Reject할 충분한 근거가 없어 키와의 관련성이 통계적으로 유의하다고 보기 어렵다고 해석할 수 있다.

(Q7) Multiple hypothesis tests on the same data raise certain statistical issues due to their "significance level" concept. This part was not covered in class, but it is one of the most important statistical issues in the era of modern data science. I believe that you can understand this concept by studying it a little if you have followed the course normally. After studying this issue through Googling, **please describe in (Q5) what is causing the problem in your project.** Also, if possible, look for a solution, then **modify the P-value from your project (Q5) and describe it.** (*Tip: There are so many correction methods such as Bonferroni, Scheffe, Sidak, and Benjamini & Hochberg methods). **(10 points).**

(Kor: 동일 자료에 대한 복수의 가설 검정은 "유의수준" 컨셉에 의해 특정 통계적 문제를 야기합니다. 이에 대해서는 수업시간에 다루지 않았지만, 현대 데이터 사이언스 시대에서 사용되는 통계적 분석에서 가장 중요한 이슈 중 하나입니다. 본 수업을 정상적으로 따라왔다면, 약간의 구글링을 통해 이를 쉽게 이해할 수 있을 것이라 믿습니다. 구글링을 통해 이 이슈를 공부한 뒤, 여러분이 수행한 (Q5)에서 어떤점이 이런 문제를 야기시키는지에 대해서 서술하십시오. 또한, 가능하다면 이를 해결하는 다양한 방법을 이용해서 여러분이 수행한 (Q5)의 결과를 수정한 뒤 서술하십시오. 팁을 주자면, 상당히 많은 솔루션이 존재하며 R로 구현되어 있습니다. 예: Bonferroni, Scheffe, Sidak, and Benjamini & Hochberg 방법).

[Answer] 1 page limit.

(Q5)에서는 72명의 자료에서 1,274개의 유전자 각각에 대해 Cancer-group과 Healthy-group의 평균이 같은지를 검정하면서 Welch의 two-sample t-test를 사용하고, 유의수준 1%에서 Null hypothesis(두 집단의 평균은 같다)을 검정하였다. p-value < 0.01인 경우 귀무가설을 Reject하고 Alternative hypothesis를 Select하였으며, 그 결과 유의한 유전자는 총 315개로 나타났다.

그러나 이와 같이 같은 데이터에서 1,274개의 가설을 동시에 검정하는 것은 다중 가설검정 문제를 발생시킨다. 개별 검정마다 Significance level 1%를 적용하면, 실제로는 차이가 없는 유전자라도 우연히 p-value < 0.01이 되어 Null hypothesis를 잘못 Reject할 확률이 누적된다. 따라서 Q5에서 얻은 315개의 유의 유전자 중에는 다중 검정으로 인해 우연히 유의해 보이는 false positive가 상당수 포함되어 있을 가능성이 크다는 점이 문제이다.

이 문제를 완화하기 위하여 이번 문항에서는 다중 가설검정을 보정하는 방법을 적용하였다. 먼저, 각 유전자의 원래 p-value에 대해 **Bonferroni 보정**과 **Benjamini-Hochberg(BH) 보정**을 적용하여 두 종류의 보정된 p-value를 계산하였다. 유의수준은 1%를 유지하고, 보정된 p-value < 0.01인 유전자에 대해서만 최종적으로 Null hypothesis를 Reject, Alternative hypothesis를 Select하였다. 그 결과, 보정 전(raw p-value 기준)에는 유의한 유전자가 315개였으나, Bonferroni 보정 후에는 p_bonf < 0.01인 유전자가 56개, Benjamini-Hochberg 보정 후에는 p_bh < 0.01인 유전자가 185개로 줄어들었다.

따라서 Bonferroni 보정을 기준으로 보면, Significance level 1%에서 최종적으로 Null hypothesis를 Reject하고 Alternative hypothesis를 Select할 수 있는 유전자는 56개이며, 이 유전자들은 다중 가설검정 문제를 고려한 뒤에도 여전히 통계적으로 유의한 차이를 보이는 보다 보수적으로 선별된 후보라고 해석할 수 있다. Benjamini-Hochberg 보정을 사용할 경우에는 185개의 유전자가 남는데, 이 방법은 거짓 발견률을 통제하는 방식으로, Bonferroni보다 덜 보수적이면서도 다중 검정 문제를 일정 수준 반영하는 절충적인 방법이다. 요약하면, Q5의 원래 결과는 다중 가설검정으로 인한 제1종 오류 누적 문제를 안고 있으며, Q7에서 Bonferroni 및 Benjamini–Hochberg 보정을 적용하여 p-value를 수정함으로써 다중 검정을 고려한 보다 신뢰도 높은 유전자 집합을 얻었다고 결론 내릴 수 있겠다.

(Q8) The technology you developed in (Q5) and (Q6) is currently being used as a very important technology in the fields of artificial intelligence and data science. Please describe logically how the statistically significant results you obtained in (Q5) and (Q6) could be applied in real industrial & academic fields **(10 points).**

*Tip: Please explain what statistically significant results mean in (Q5) and (Q6). Based on the this explanation, you can draw the usage of those outcomes.

(Kor: (Q5) 와 (Q6)에서 여러분이 펼친 기술은 현재 인공지능 및 데이터사이언스 분야에서 매우 중요한 기술로 활용되고 있습니다. 여러분이 (Q5)와 (Q6)에서 통계적으로 유의한 결과를 얻은 것들이 실제 산업 또는 학술 현장에서 어떻게 활용될 수 있을지 논리적으로 기술하십시오. (Tip: (Q5)와 (Q6)에서 통계적으로 유의한 결과라는 것들이 각각 무슨 의미인지에 대해서 설명하고, 이 설명을 바탕으로 어떻게 응용될 수 있을지에 대해 기술하십시오.)

[Answer] 1 page limit.

먼저 Q5와 Q6에서 얻은 **"통계적으로 유의한 결과"**가 무엇을 의미하는지 정리하는 것이 필요하다. Q5에서 각 유전자에 대해 수행한 가설검정에서 Null hypothesis은 "해당 유전자의 평균 발현값은 Cancer-group과 Healthy-group에서 같다"이고, Alternative hypothesis은 "두 집단의 평균 발현값은 다르다"이다. 유의수준 1%에서 p-value가 0.01보다 작은 유전자들에 대해 Null hypothesis를 Reject하고 Alternative hypothesis를 Select하였다는 것은, 이 유전자들이 단순한 우연이 아니라 실제로 질병 유무와 체계적으로 연관되어 있을 가능성이 높다는 의미이다. Q7에서 다중 가설검정을 보정한 뒤에도 남는 유전자들은, 이러한 연관성이 더 신뢰할 수 있는 후보라고 해석할 수 있다.

Q6에서도 마찬가지이다. 각 유전자와 키(Height) 사이의 상관관계 검정에서 Null hypothesis은 "해당 유전자와 Height 사이의 상관계수는 0이다(상관 없음)"이고, Alternative hypothesis은 "상관계수가 0이 아니다(상관 있음)"이다. 유의수준 1%에서 p-value가 0.01보다 작은 유전자에 대해 Null hypothesis을 Reject하고 Alternative hypothesis를 Select하였다는 것은, 이 유전자들이 Height와 통계적으로 유의한 관련성을 가진다는 의미이다. 즉, 이 유전자들은 신체 성장, 골격 발달 등과 관련된 생물학적 기전에 잠재적으로 관여할 가능성이 있는 후보로 볼 수 있다.

이러한 **"유의한 유전자들"**은 다양한 방식으로 활용될 수 있다. 먼저 Q5의 결과는 암 진단 및 예측 모델 개발에 직접적으로 사용 가능하다. Cancer-group과 Healthy-group 사이에서 통계적으로 유의한 유전자는 인공지능·머신러닝 분류 모델에서 중요한 입력 특성(feature)로 사용될 수 있다. 예를 들어, 이 유전자들만을 선별하여 로지스틱 회귀, 랜덤 포레스트, 신경망 모델 등을 학습시키면, 유전자 발현 패턴을 기반으로 암 여부를 예측하는 진단 모델을 설계할 수 있다. 진단 키트나 유전자 패널을 설계할 때도, 통계적으로 유의한 유전자를 우선 후보로 삼아 비용 효율적이고 정확한 검사법을 개발하는 데 활용할 수 있다.

Q6의 Height 관련 유의 유전자들은 성장 관련 질환 연구나 개인 맞춤형 의료에서 활용할 수 있다. 예를 들어, 성장 장애나 골격 발달 이상과 같은 임상 문제에서, Height와 유의한 상관을 보이는 유전자들을 중심으로 추가 연구를 설계하여 위험 예측 모델을 만들 수 있다. 인공지능 모델에 이 유전자들을 특징으로 넣어 성장 패턴이나 질환 위험을 예측하고, 장기적으로는 개인의 유전 정보에 기반한 맞춤형 영양·운동·치료 전략을 설계하는 데 활용할 수 있다.

-At the end- Well done for one semester!